Rapport SAE :
Description et Prévision de séries temporelles

BUT Science des Données
Parcours Exploration et Modélisation Statistique (EMS)

Groupe : Margot Marciano, Arthur Renault-Clequin
Encadrant : M. Gomez Garcia
Année universitaire : 2025-2026

SOMMAIRE

1. Introduction p.3

2. Analyse descriptive de la série nucléaire p.4
   2.1 Visualisation générale p.4
   2.2 Analyse de la tendance p.5
   2.3 Analyse de la saisonnalité p.6
   2.4 Décomposition de la série et analyse de la série désaisonnalisée p.7
   2.5 Analyse des résidus p.8

3. Prévision de la production pour 2025 ..... p.9
   3.1 Modèle polynomial p.9
   3.2 Modèle de Holt-Winters p.9
   3.3 Modèle SARMA p.10

4. Comparaison et évaluation des modèles p.11
   4.1 Méthode de comparaison des modèles p.11
   4.2 Analyse des EQM et choix du meilleur modèle p.11
   4.3 Comparaison graphique des prévisions et des observations p.12

5. Bilan général et éléments complémentaires p.13
   5.1 Bilan général p.13
   5.2 Summary p.13
   5.3 Organisation du travail du binôme p.13

6. Annexe p.14

1. Introduction

Dans cette étude le jeu de données utilisé provient de l'Agence américaine d'information sur l'énergie (EIA), un organisme officiel du Système Statistique Fédéral des États-Unis chargé de collecter et diffuser des données fiables sur le secteur énergétique. L'EIA publie notamment de nombreuses séries temporelles mensuelles reconnues pour leur qualité. Dans le cadre de la SAE « Description et Prévision de séries temporelles », nous étudions ici la production mensuelle d'électricité nucléaire entre janvier 2001 et décembre 2024, exprimée en milliers de mégawatt-heures (MWh). Le fichier utilisé contient une seule variable : la production nucléaire mensuelle.

Au début du projet, nous envisagions deux sources d'énergie : le charbon et le nucléaire. Pour effectuer notre choix, nous avons comparé leurs séries temporelles afin d'évaluer leur comportement global et la régularité de leur saisonnalité *(voir annexe 1)*. La série du charbon présente une forte tendance décroissante et des variations importantes d'une année à l'autre, ce qui la rend plus instable et difficile à modéliser. À l'inverse, la série nucléaire montre une production plus stable et une saisonnalité beaucoup plus régulière. Dans l'objectif d'obtenir des prévisions fiables, nous avons donc retenu l'énergie nucléaire comme variable d'étude.
Pour prévoir la production d'électricité en 2025, nous avons ensuite appliqué trois méthodes présentées en cours : le modèle polynomial, le modèle Holt-Winters et le modèle SARMA. Ces approches ont été comparées à l'aide de l'erreur quadratique moyenne, ce qui nous a permis d'identifier, de manière objective, le modèle offrant la meilleure qualité de prévision pour notre série.

2. Analyse descriptive de la série nucléaire

2.1 VISUALISATION GÉNÉRALE

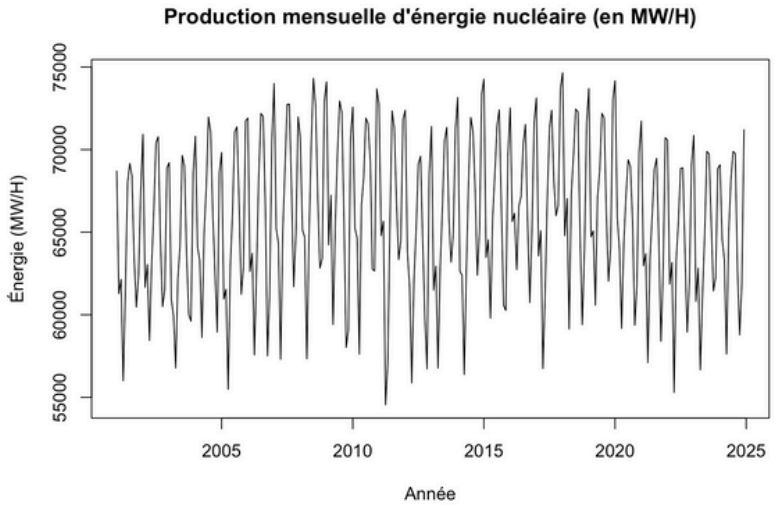

La visualisation globale de la série nucléaire montre une production d'électricité relativement stable entre 2001 et 2024, oscillant principalement entre 58 000 et 75 000 MWh. La série présente des variations régulières d'une année à l'autre, ce qui suggère la présence d'une saisonnalité bien marquée. On n'observe pas de tendance nette à la hausse ou à la baisse sur l'ensemble de la période, ce qui signifie que la production nucléaire reste globalement constante dans le temps, malgré quelques fluctuations ponctuelles.

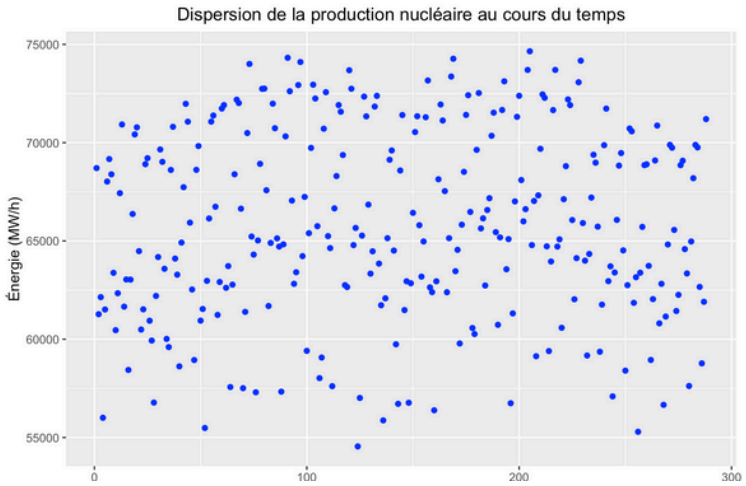

Le nuage de points confirme cette impression de stabilité. Les valeurs sont réparties autour d'un niveau moyen constant, sans croissance ou décroissance évidente. La dispersion des points reste relativement similaire tout au long de la période, ce qui indique que les fluctuations observées correspondent principalement à des variations récurrentes d'un mois à l'autre, autrement dit à une saisonnalité mensuelle, plutôt qu'à une évolution structurelle de long terme.

2.2 ANALYSE DE LA TENDANCE

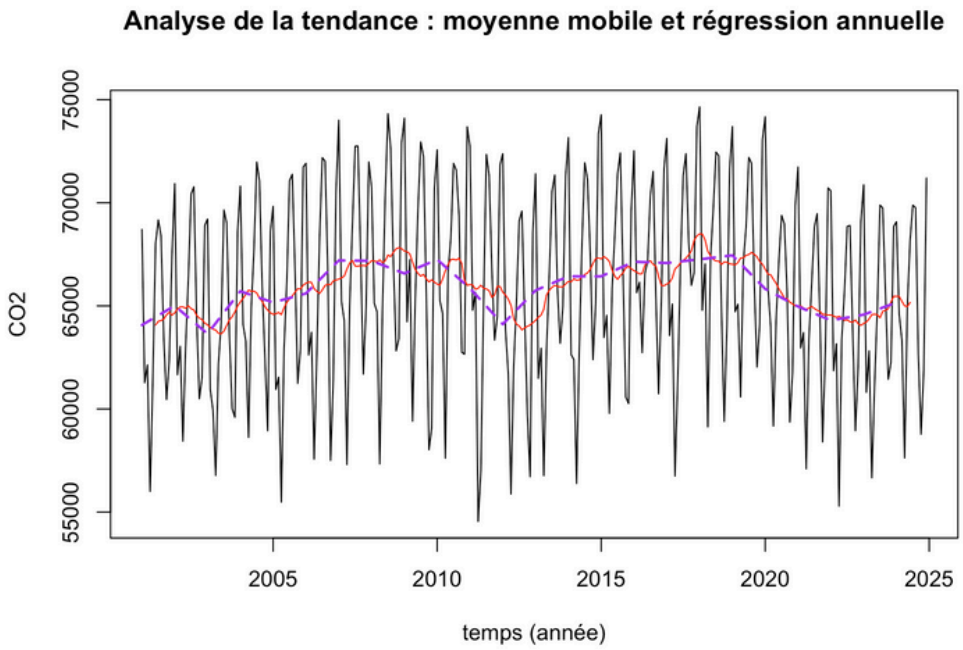

Pour analyser l'évolution générale de la production nucléaire, nous avons utilisé deux méthodes de lissage : la moyenne mobile sur 12 mois (MM12) et les moyennes annuelles. La courbe MM12 (en rouge) atténue les variations mensuelles et permet de rendre la tendance plus lisible, tandis que la courbe des moyennes annuelles (en violet) met en évidence l'évolution moyenne d'une année à l'autre.

L'observation de ces deux courbes montre que la série ne suit pas une trajectoire durablement croissante ou décroissante. Au contraire, la production connaît successivement des phases de hausse puis de baisse : une augmentation progressive jusqu'en 2008, une diminution autour de 2012, puis une nouvelle remontée dans la seconde moitié des années 2010, avant de redescendre légèrement par la suite. Ces mouvements alternés ne s'installent jamais dans une direction unique sur la période observée.

Ces fluctuations montrent que la série ne présente pas de tendance à long terme clairement définie. Elles indiquent que son comportement dépend surtout de variations saisonnières, qui seront étudiées dans la partie suivante.

2.3 ANALYSE DE LA SAISONNALITÉ

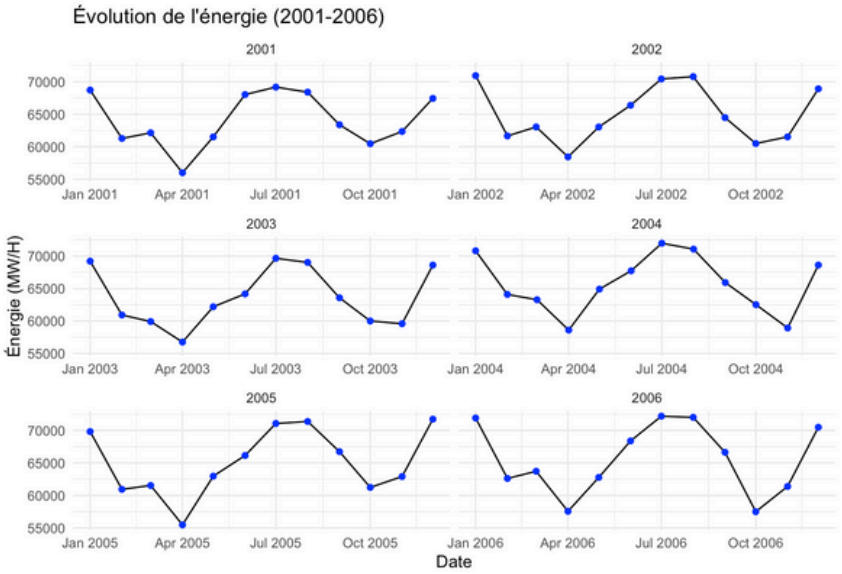

Pour étudier la saisonnalité de la production d'électricité nucléaire, nous avons d'abord réalisé un zoom sur les six premières années de la série (2001–2006) afin d'observer si un motif récurrent apparaissait dès le début de la période. L'analyse de ces graphiques montre une saisonnalité très similaire d'une année à l'autre. La production baisse systématiquement au printemps, atteint un minimum net en avril, remonte fortement durant l'été, puis diminue à nouveau à l'automne. Cette répétition dès les premières années indique que la série présente une saisonnalité mensuelle stable.

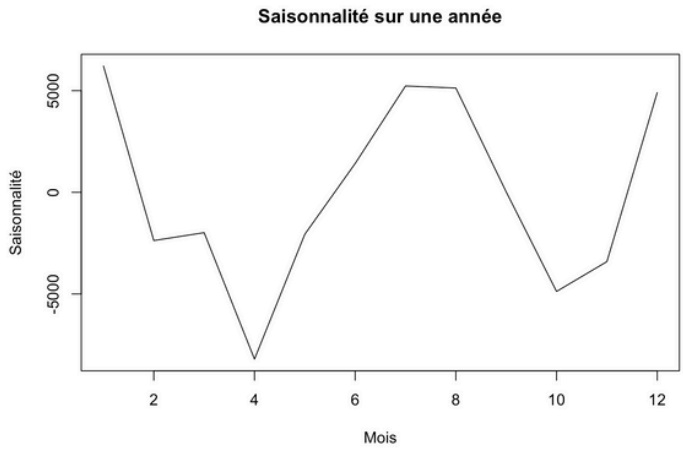

La saisonnalité annuelle confirme le même schéma observé dans le zoom des premières années. La production est plus faible en avril, puis augmente rapidement entre mai et août avant de diminuer en septembre et octobre et de remonter en fin d'année. Ce cycle correspond au fonctionnement du parc nucléaire, avec des arrêts de maintenance fréquents au printemps et une demande énergétique plus élevée durant l'été et l'hiver.
Dans l'ensemble, le zoom annuel et la saisonnalité moyenne montrent que la production nucléaire suit un motif annuel très régulier, marqué par un creux au printemps et des niveaux plus élevés en été et en fin d'année. Ce cycle régulier joue un rôle important dans la série et doit être pris en compte dans les modèles de prévision.

2.4 DÉCOMPOSITION DE LA SÉRIE ET ANALYSE DE LA SÉRIE DÉSAISONNALISÉE

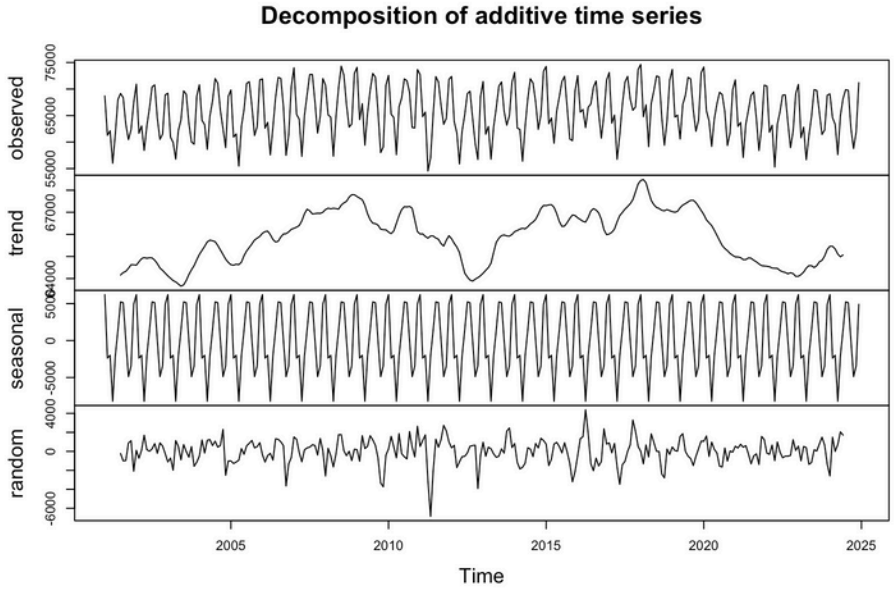

La décomposition additive met clairement en évidence la structure de la série nucléaire. La série observée présente des fluctuations mensuelles très régulières, ce qui confirme une saisonnalité forte et stable dans le temps. La tendance révèle plusieurs phases distinctes : une hausse progressive jusqu'en 2009, suivie d'un creux marqué entre 2010 et 2015, puis d'une remontée jusqu'en 2018 avant une baisse plus nette sur les dernières années. Ce creux central constitue l'évolution structurelle la plus visible de la période. La composante saisonnière reste parfaitement répétitive, avec la même amplitude et le même motif chaque année, ce qui montre que la saisonnalité est stable et prévisible. Enfin, le résidu est relativement faible et ne montre pas de forme particulière, ce qui indique que la tendance et la saisonnalité expliquent l'essentiel de la dynamique de la série.

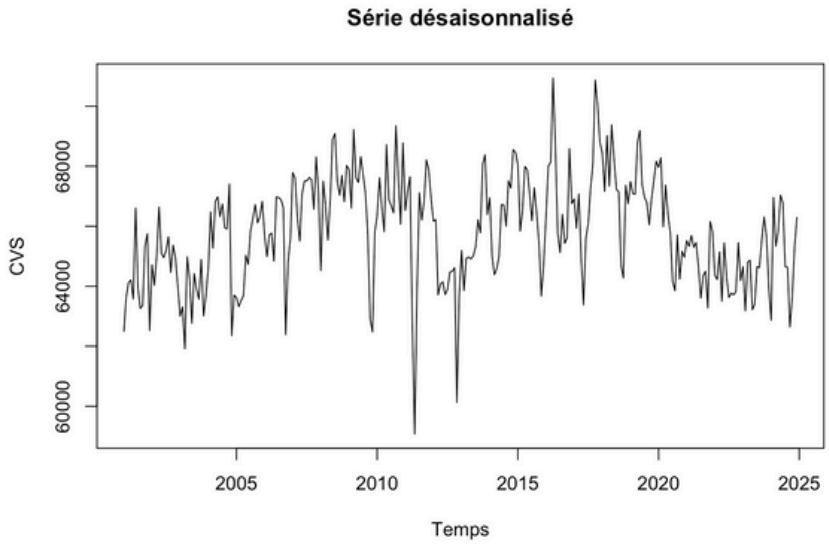

La série désaisonnalisée met en évidence l'évolution générale de la production nucléaire une fois retirées les variations mensuelles. La production reste le plus souvent comprise entre 62 000 et 69 000 MWh. On voit une légère hausse pendant les années 2000, puis une baisse marquée autour de 2011–2012, suivie d'une nouvelle période plus élevée jusqu'en 2018. Les dernières années montrent ensuite une diminution progressive. Sans la saisonnalité, ces mouvements apparaissent plus nettement et révèlent plusieurs cycles modérés qui étaient moins visibles dans la série brute.

Le creux observé en 2011–2012 correspond à une période bien documentée du parc nucléaire américain. Plusieurs réacteurs majeurs ont été arrêtés, notamment Crystal River (à la suite d'un problème structurel entre 2009 et 2011) et San Onofre, mis à l'arrêt en 2012 puis fermé définitivement en 2013, ce qui a supprimé plusieurs gigawatts de capacité. L'essor du gaz naturel issu du shale gas a également rendu cette énergie plus compétitive, réduisant l'utilisation de certaines centrales nucléaires. Enfin, l'accident nucléaire de Fukushima en 2011 a entraîné un renforcement des exigences de sûreté, provoquant davantage d'arrêts prolongés et accentuant la baisse observée dans la série.

Dans l'ensemble, l'analyse montre que la production nucléaire américaine est influencée par une saisonnalité très régulière, mais aussi par des événements spécifiques du parc nucléaire et du marché de l'énergie.

2.5 ANALYSE DES RÉSIDUS

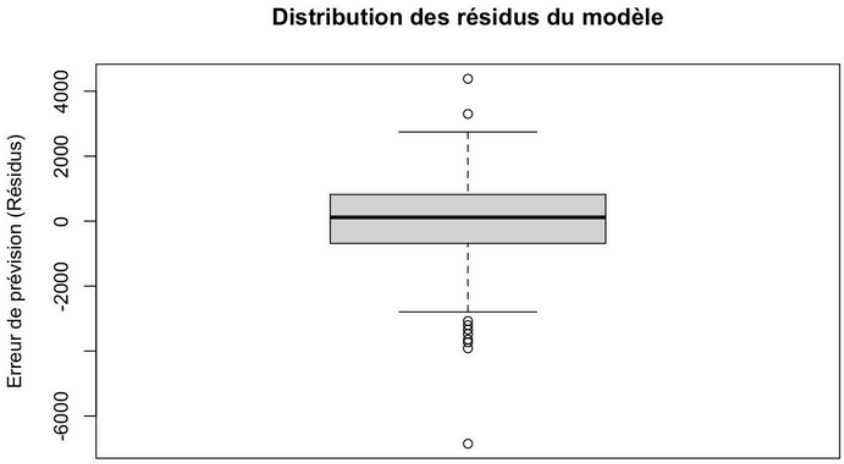

La boîte à moustaches des résidus montre que la majorité des erreurs de prévision se concentre autour de zéro, ce qui indique que les écarts entre la production réelle et la production attendue restent globalement limités. La dispersion est modérée, ce qui suggère que la production varie généralement de manière régulière d'un mois à l'autre. On observe cependant plusieurs points atypiques, principalement des résidus fortement négatifs ainsi que deux résidus très élevés.

Ces écarts importants correspondent à des situations particulières du secteur nucléaire, comme des arrêts de réacteurs plus longs que prévu, des maintenances exceptionnelles, ou au contraire des périodes de forte mobilisation du parc pour répondre à une demande accrue d'électricité. Dans l'ensemble, la variabilité des résidus est faible, ce qui indique que la production nucléaire évolue de façon assez régulière, avec seulement quelques écarts liés à des situations particulières.

3. Prévision de la production 2025

3.1 MODÈLE POLYNOMIAL

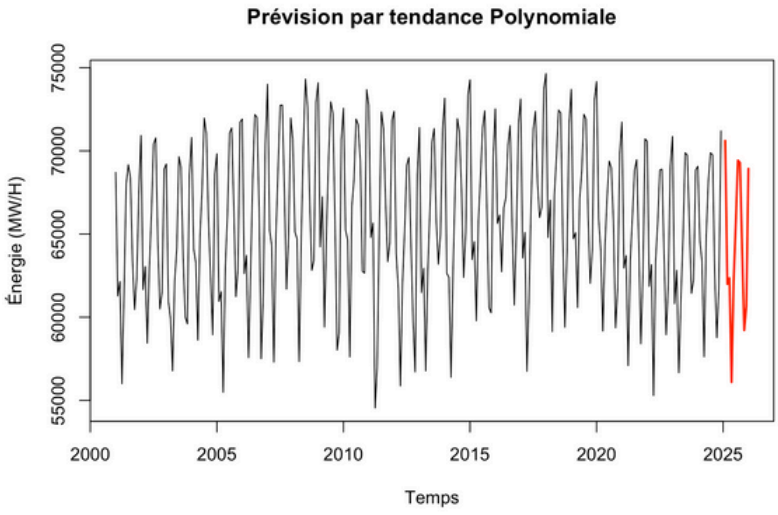

Le modèle de prévision basé sur une tendance polynomiale et la saisonnalité permet de prolonger de manière cohérente la dynamique de la série. Sur le graphique, la partie en rouge correspond aux valeurs prévues pour l'année 2025. On observe que le modèle reproduit fidèlement le motif saisonnier historique : une baisse marquée au printemps, une forte remontée durant l'été, puis une diminution à l'automne avant une nouvelle hausse en fin d'année, notamment en décembre. La tendance polynomiale ajuste le niveau général des prévisions à celui des dernières observations, ce qui explique pourquoi les valeurs prévues se situent dans la continuité des années récentes. Ce modèle reste principalement descriptif, il prolonge les formes passées en s'appuyant sur la régularité de la saisonnalité, ce qui en fait une première approche pertinente avant d'explorer des méthodes de prévision plus avancées dans la suite de l'étude.

3.2 MODÈLE DE HOLT-WINTERS

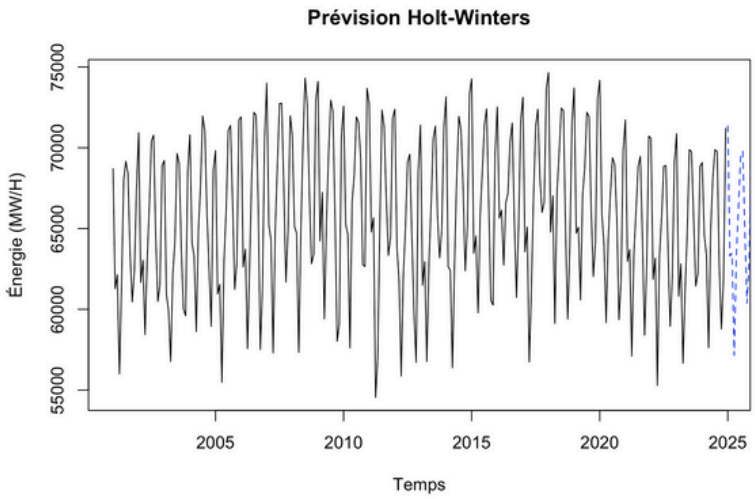

Nous avons choisi la méthode de Holt-Winters comme deuxième modèle de prévision, car elle est bien adaptée aux séries chronologiques qui présentent à la fois une tendance stable et une saisonnalité marquée, deux caractéristiques importantes de notre série de production nucléaire. Les prévisions obtenues pour l'année 2025 restent cohérentes avec les valeurs observées entre 2020 et 2024. Elles se situent majoritairement entre 57 000 et 70 000 MWh, ce qui correspond à la plage habituelle de la série. Le modèle prolonge la dynamique récente sans rupture et conserve une amplitude stable tout en reproduisant correctement les variations mensuelles. Cette continuité montre que Holt-Winters a bien reproduit le rythme régulier de la série et fournit des prévisions réalistes pour le court terme.

3.3 MODÈLE SARMA

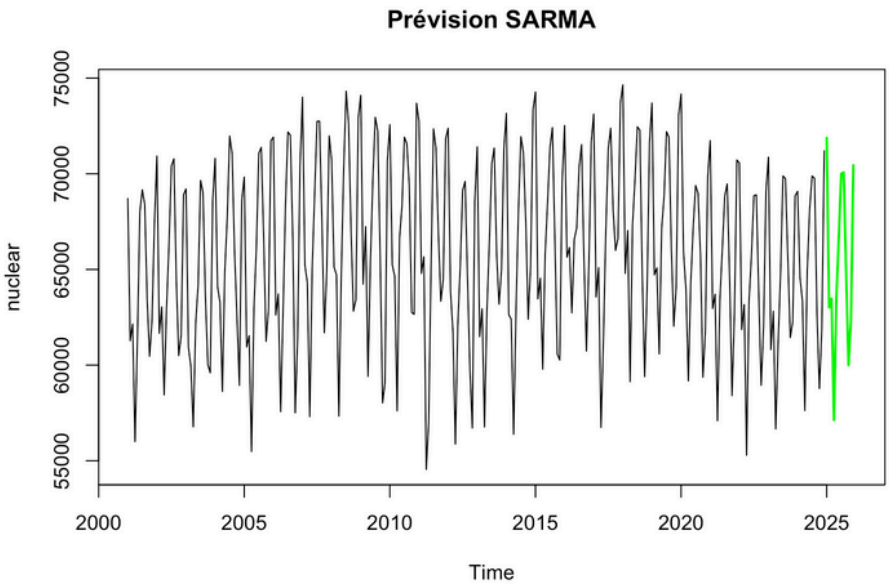

Enfin, nous avons appliqué le modèle prédictive SARMA, particulièrement adapté aux séries présentant à la fois une dépendance temporelle et une saisonnalité marquée. La prévision pour 2025 (courbe verte) reste proches des niveaux observés sur les dernières années, ce qui montre que le modèle prolonge de manière réaliste le comportement récent de la série. Le modèle conserve la structure saisonnière tout en réagissant davantage aux fluctuations observées en fin de période. Cette sensibilité donne parfois une amplitude légèrement différente de celle des autres modèles, mais dans notre cas, elle reflète une meilleure adaptation aux évolutions récentes de la série.

Globalement, le SARMA reproduit fidèlement la dynamique de la série et offre des prévisions réalistes pour le court terme. Le fait qu'il s'ajuste plus finement aux variations permet souvent d'obtenir une meilleure précision prédictive, ce qui sera confirmé dans la comparaison finale des EQM.

4. Comparaison et évaluation des modèles

4.1 MÉTHODE DE COMPARAISON DES MODÈLES

Pour comparer nos trois modèles de prévision (polynomial, Holt-Winters et SARMA, nous utilisons l'Erreur Quadratique Moyenne (EQM ou MSE (en anglais)), un indicateur classique qui mesure l'écart entre les valeurs réellement observées en 2024 et celles prédites par chaque modèle.

Sa formule est : $$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2$$

Un EQM faible signifie que les prévisions sont proches des valeurs réelles.

Ainsi, dans notre jeu de données , le meilleur modèle sera celui qui obtient l'EQM le plus faible, car il reproduit le mieux les observations de 2024.

4.2 ANALYSE DES EQM ET CHOIX DU MEILLEUR MODÈLE

Méthode	EQM
SARMA	2 077 487
Polynomiale	2 779 387
Holt-Winters	3 025 590

Nous avons d'abord créé un tableau regroupant les trois EQM associés à chaque modèle de prévision, afin de faciliter la lecture et la comparaison des résultats. Les valeurs obtenues montrent que l'EQM le plus faible correspond au modèle SARMA (environs 2,08 millions), ce qui indique qu'il s'agit du modèle qui reproduit le plus fidèlement les observations de 2024 parmi les trois méthodes étudiées. Son erreur reste élevée en valeur absolue, ce qui est logique compte tenu du niveau important de la production nucléaire, mais elle demeure nettement inférieure à celles des modèles polynomiaux et Holt-Winters.

Le modèle polynomial se place en deuxième position avec un EQM intermédiaire, tandis que Holt-Winters présente l'EQM le plus élevé, révélant des prévisions moins précises pour notre série. Globalement, le modèle SARMA apparaît donc comme le plus performant pour notre jeu de données, car il fournit les prévisions les plus proches des valeurs réellement observées, même si l'erreur absolue reste élevée en raison de l'échelle des données.

4.3 COMPARAISON GRAPHIQUE DES PRÉVISIONS ET DES OBSERVATIONS

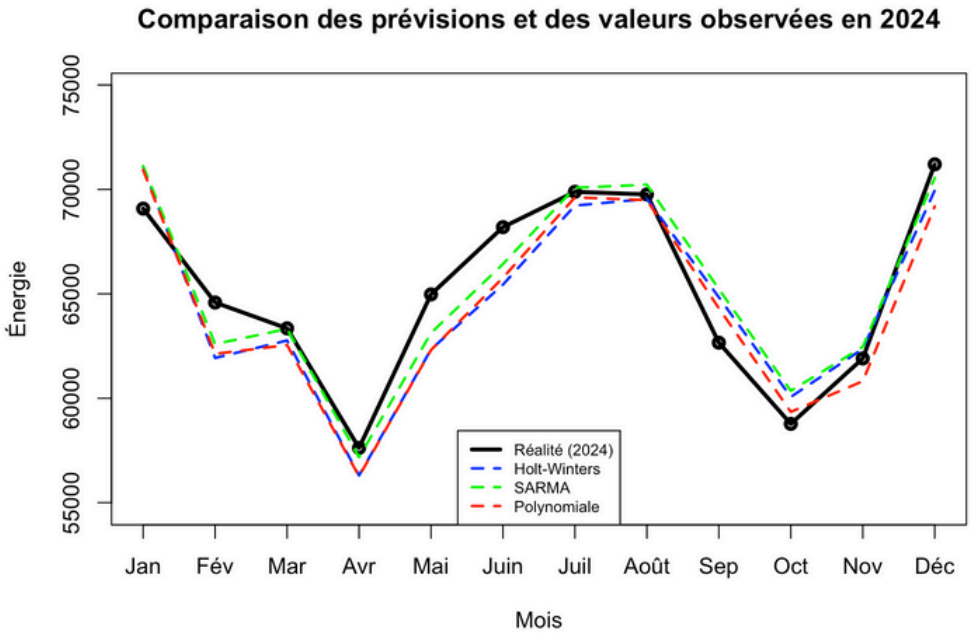

L'analyse du graphique comparant les valeurs réelles de 2024 aux prévisions des trois modèles montre que chacun parvient à reproduire la forme générale de la série, avec une baisse en début d'année, un creux au printemps, une remontée durant l'été puis une hausse en fin d'année. Cela confirme que les trois approches captent bien la saisonnalité mise en évidence dans l'analyse descriptive.

En observant plus précisément les écarts, le modèle SARMA (vert) est celui dont la courbe reste la plus proche des valeurs observées. Ses prévisions suivent très fidèlement l'évolution réelle, notamment entre avril et août où la trajectoire correspond presque point par point aux données. Le modèle polynomial (rouge) restitue correctement la dynamique globale, mais lisse légèrement les variations, ce qui crée de petits décalages, en particulier lors du creux du printemps ou de la hausse de décembre. Le modèle Holt-Winters (bleu) reste globalement cohérent, mais s'écarte davantage dans certaines phases de changement, comme la chute du début d'année ou la remontée finale.

Dans l'ensemble, cette comparaison visuelle confirme les conclusions obtenues avec l'EQM: le modèle SARMA est le plus précis, tandis que le modèle polynomial et Holt-Winters offrent des prévisions satisfaisantes mais légèrement moins proches des observations.

5. Bilan général et éléments complémentaires

5.1 BILAN GÉNÉRAL

L'étude menée sur la production nucléaire américaine entre 2001 et 2024 montre une série très stable. Les niveaux de production varient peu d'une année à l'autre et suivent un cycle saisonnier régulier. Le creux du printemps, les valeurs plus hautes en été et la remontée en fin d'année se répètent presque exactement chaque année. Cette régularité explique pourquoi la série ne présente que peu d'irrégularités et pourquoi les modèles de prévision fonctionnent bien.

L'analyse de la tendance et de la série désaisonnalisée confirme l'absence de changements majeurs à long terme. Seule la période autour de 2011–2012 se distingue, en lien avec des arrêts de réacteurs et des évolutions du marché de l'énergie. En dehors de cet épisode, la production reste remarquablement constante et suit un rythme très prévisible. Les modèles de prévision testés restituent correctement cette dynamique, en particulier le modèle SARMA, qui est celui qui s'ajuste le mieux aux données. Il obtient l'EQM le plus faible et reproduit fidèlement les variations de la série. Pour aller plus loin, nous avons utilisé ce modèle afin de réaliser une prévision sur cinq ans. Les résultats montrent que la production resterait globalement stable, ce qui confirme le caractère très régulier de la série *(voir annexe 2).*

De manière générale, ce travail montre qu'une bonne compréhension de la structure temporelle d'une série est essentielle avant de choisir un modèle. Dans notre cas, la forte stabilité du nucléaire facilite la prévision et met en valeur la performance du modèle SARMA pour le court et moyen terme.

5.2 SUMMARY

This study analyzes monthly nuclear electricity production in the United States from 2001 to 2024. The series is highly stable and shows a clear seasonal pattern, with lower production in spring and higher levels in summer and at the end of the year. Apart from a temporary decline around 2011–2012, linked to reactor shutdowns and changes in the energy market, the overall trend remains steady.
Three forecasting methods were tested for the year 2025: polynomial regression, Holt-Winters, and SARMA. The SARMA model provided the most accurate results, with the lowest mean squared error. It reproduced the seasonal structure of the series more effectively than the other models.
A five-year forecast based on the SARMA model shows that nuclear production is expected to remain stable, confirming the strong regularity of the series.

5.3 ORGANISATION DU TRAVAIL DU BINÔME

La répartition du travail au sein de notre binôme a été équilibrée tout au long du projet. Nous avons tous les deux travaillé sur le code, aussi bien pendant les heures d'autonomie que lors des séances où nous pouvions vous demander des conseils pour améliorer les graphiques et les méthodes de prévision. Pour la rédaction du rapport, Arthur s'est chargé des parties 1 et 2, tandis que Margot a rédigé les parties 3, 4 et 5. Cependant, si l'un de nous rencontrait une difficulté, l'autre apportait son aide ou relisait la partie concernée.

6. Annexes

ANNEXE 1

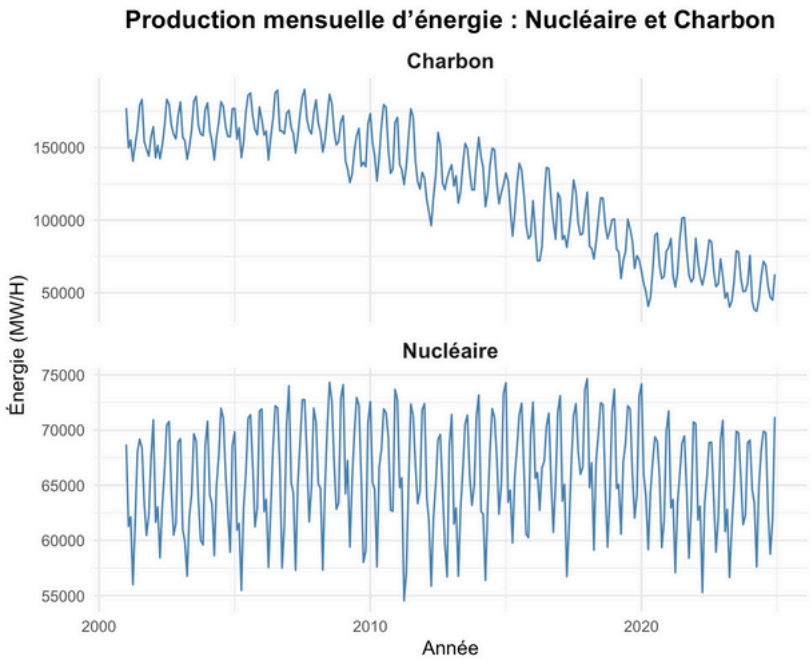
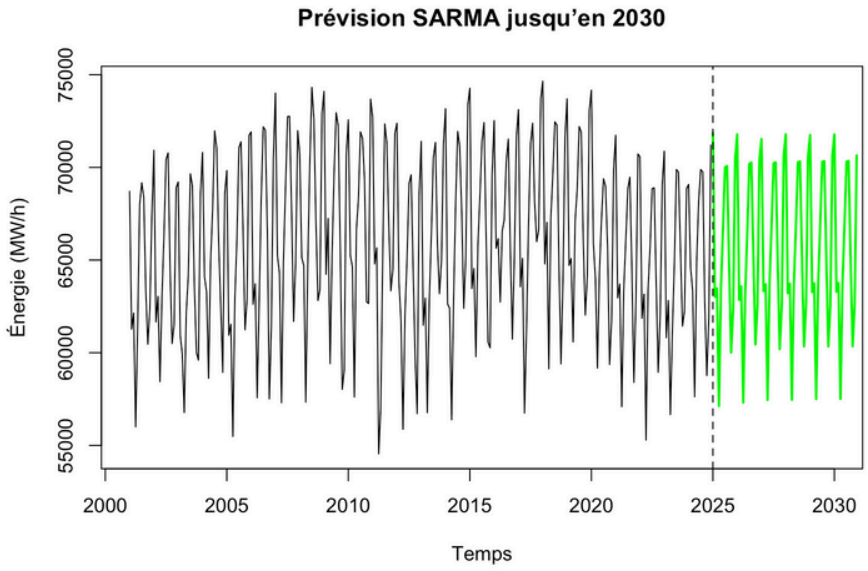
ANNEXE 2